

人工智能（研讨）课程报告

结合 ReID 问题分析过拟合问题及其解决方法

姓名：梁耀欣

学号 09022107

东南大学

计算机科学与工程学院

计算机科学与技术

目录

1 综述	2
2 什么是过拟合？	2
3 在 ReID 问题中解决过拟合的具体方法	4
3.1 过拟合问题的演变过程	4
3.1.1 早期解决方案——数据增强和简单正则化	4
3.1.2 归一化技术的引入——BN 和 IN	4
3.1.3 风格归一化与恢复策略——SNR 模块	4
3.2 MetaBIN 框架的提出及其工作机制	4
3.2.1 BN 和 IN 的自适应平衡	5
3.2.2 失败情境模拟与元学习优化	5
3.2.3 循环内更新的增强效果	6
3.2.4 综合损失设计	6
3.3 MetaBIN 框架的过拟合缓解效果	6
3.3.1 增强跨域泛化能力	6
3.3.2 降低风格依赖性	7
3.3.3 维持身份辨识能力	7
4 在深度学习领域的推广	8
5 结论	8

1 综述

在数据建模和机器学习中，线性回归作为一种简单而有效的预测模型，因其能直观地揭示变量间关系，广泛应用于各个领域。然而，线性回归模型若在训练过程中对数据依赖过强，会导致模型出现“过拟合”现象，即对训练数据的模式学习过度，难以泛化至新的数据，从而在测试集上表现不佳。过拟合问题不仅在回归模型中常见，还广泛存在于更为复杂的深度学习模型，尤其是需要处理高维、复杂图像数据的任务，如人脸识别、物体分类和目标重识别（Re-identification, ReID）等。

目标重识别是一种计算机视觉任务，旨在从多个非重叠的摄像机中识别出特定目标个体，常见于监控、安防等应用场景中。与一般的图像分类不同，ReID 任务的主要挑战在于模型需要在多个视角和环境下准确识别目标。对于训练模型的 ReID 数据集，往往需要满足以下条件，以确保模型具有良好的泛化能力：

- **多样性：** ReID 数据集需包含不同摄像头下的多种风格、光照和姿势变化，以便模型能在不同环境中识别同一目标。
- **跨域适应性：** 实际应用中，模型通常会在与训练环境不同的域上运行，要求数据集涵盖尽可能多的域特征，以提高模型的跨域适应性。
- **平衡性：** 数据集中目标个体数量及其图像数量应尽量平衡，以避免模型偏向少数样本量大的个体。

然而，即便如此，现有的 ReID 模型仍易遭受过拟合问题的影响。在《Meta Batch-Instance Normalization for Generalizable Person Re-Identification》论文中，作者指出，传统的监督 ReID 模型在单一域内的表现虽优异，但在跨域迁移时易出现过拟合，导致模型泛化能力差。尤其是在 ReID 任务中，跨域数据风格和分布差异较大，直接训练的模型往往会偏向训练集中的特定风格，在新域上的表现显著下降。

为了解决上述问题，研究者引入了 Meta Batch-Instance Normalization (MetaBIN) 框架，通过模拟泛化失败的情境，使模型在训练中接触各种“失败”情况，提升其在未知域上的鲁棒性。本文将进一步探讨过拟合的定义及其成因，分析其在 ReID 任务中的现状，并介绍有效的解决方法，包括 MetaBIN 框架所采用的元学习优化策略，以提升模型的泛化能力和性能。

2 什么是过拟合？

过拟合是指机器学习模型在训练过程中对训练数据中的模式和细节学得过于深入，甚至学习了数据中的噪声。这使得模型对训练数据的表现极佳，但当面对新的数据或测试集时，无法很好地推广或泛化。即，模型能够很好地“记住”训练集中的数据模式，但

在面对未见过的数据时表现较差，无法做出准确预测。过拟合的主要原因包括模型复杂度过高、特征数量过多、训练数据不足等。

在 ReID 任务中，过拟合问题尤为严重。ReID 需要在不同的视角、光照和背景下识别出同一目标，而跨域数据集的分布差异和风格不一致，使模型更容易“记住”训练集中的特定环境或风格，而非个体本身的特征。在文献中，作者强调了在 ReID 任务中的过拟合现象，尤其是在跨域人脸识别中。传统的 ReID 模型通常采用单一域的训练数据，模型在该域内能达到较好的识别率，但在未见过的新域数据上则性能大幅下降，表现出过拟合的典型特征。

在 ReID 任务中，过拟合现象主要表现在风格依赖、领域偏差、缺乏身份歧视性这三个方面。模型在训练集中学到的风格特征过多，例如特定光照、背景或摄像头的风格，导致模型在其他风格的数据集上泛化不佳；跨域情况下的 ReID 模型倾向于依赖训练域中的特定背景或拍摄角度，无法有效识别目标个体。例如，模型在某一域中可能依赖于特定的环境特征，但在其他域上环境变化会导致识别性能显著下降；如果模型对环境 and 风格信息过度依赖，导致其未能专注于个体身份特征，模型可能无法有效区分不同身份的个体。

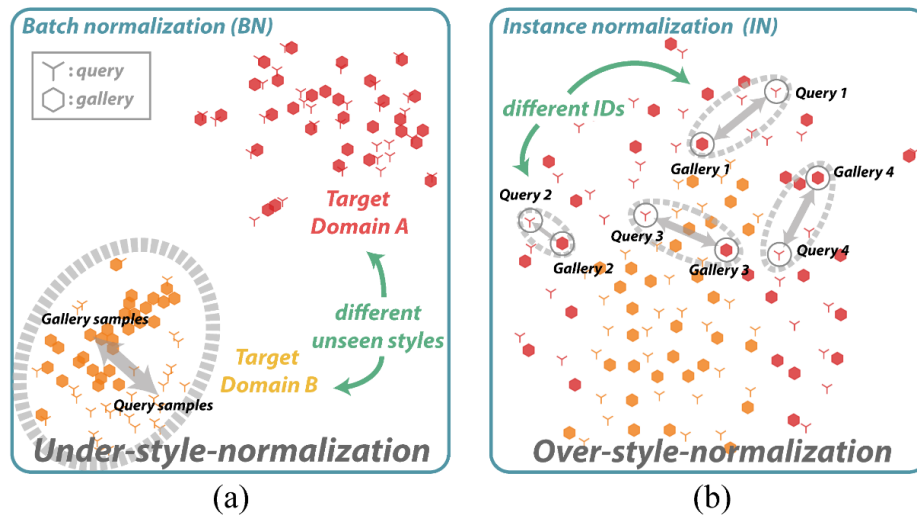


图 1: 现有导致过拟合问题的模型

过拟合问题不仅限于 ReID 任务，在整个深度学习领域普遍存在，尤其是在图像分类、语音识别、自然语言处理等需要大量特征的任务中表现突出。深度学习模型通常具有高度非线性和复杂的结构，随着层数的增加，模型的自由度显著提高。这使得模型更容易拟合训练数据中的所有模式，包括潜在的噪声和异常值，导致模型复杂度远超数据实际需求，出现过拟合现象。这对于深度学习模型的影响是不可忽略的，会使模型的泛化能力下降（模型对训练数据表现良好，但在测试数据上表现较差，难以推广到真实环境中的新数据。），影响分类性能（模型会学到训练数据中的噪声，使得预测结果不稳定。），也可能会造成计算资源浪费（对硬件和计算资源的需求显著增加，导致训练成本增加。），因此如何解决过拟合问题成为了现在研究中的一个重要方向。

3 在 ReID 问题中解决过拟合的具体方法

在 ReID 问题中，解决过拟合一直是研究的核心挑战之一。由于 ReID 模型在不同域之间的泛化能力较差，在新环境中往往表现不佳。随着研究的不断发展，解决过拟合问题的方法从传统的简单正则化逐渐演变为多种复杂策略的结合，包括数据增强、正则化技术、归一化技术以及元学习等高级方法。本文将首先简要回顾 ReID 任务中过拟合问题的解决方案的演变过程，并深入探讨 MetaBIN 框架如何通过创新的归一化策略有效缓解这一问题。

3.1 过拟合问题的演变过程

3.1.1 早期解决方案——数据增强和简单正则化

最初，研究者们尝试通过数据增强 (Data Augmentation) 和正则化 (Regularization) 来应对 ReID 模型的过拟合。例如，通过图像翻转、旋转、裁剪等数据增强方法，增加训练数据的多样性，以提高模型的泛化能力。同时，引入 L2 正则化以限制模型参数的复杂度，减少过度拟合。然而，数据增强和简单正则化的方法对不同域之间的泛化性提升有限，尤其是在域分布差异较大的情况下，模型的过拟合问题仍难以解决。

3.1.2 归一化技术的引入——BN 和 IN

随着深度学习的发展，归一化技术 (Normalization) 被证明能够显著提升模型的稳定性和泛化能力。在 ReID 任务中，研究者逐渐发现使用批归一化 (Batch Normalization, BN) 和实例归一化 (Instance Normalization, IN) 的组合能够缓解模型的过拟合问题。BN 主要用于在小批量数据中归一化特征分布，适合处理批次之间的变化；而 IN 则可通过调整每个样本内部的特征分布来抑制不必要的风格信息。然而，简单的 BN 和 IN 组合在提升模型的跨域适应性方面存在局限：BN 可能在不同风格的批次中难以区分个体，而 IN 则会丢失部分个体辨识信息，从而影响模型性能。

3.1.3 风格归一化与恢复策略——SNR 模块

针对 BN 和 IN 在不同归一化任务中的优势和劣势，研究者进一步提出了风格归一化与恢复 (Style Normalization and Restitution, SNR) 模块，该方法基于 IN 进行风格归一化，并通过特征蒸馏恢复个体特征。然而，SNR 模块的局限在于其仅对源域数据的风格差异进行消除，缺乏对目标域数据的适应能力，因此在面临未知新域时效果不佳。

3.2 MetaBIN 框架的提出及其工作机制

为解决现有归一化技术的局限性，论文提出了一种全新的框架——Meta Batch-Instance Normalization (MetaBIN)，通过创新的归一化策略和元学习相结合的方式，从

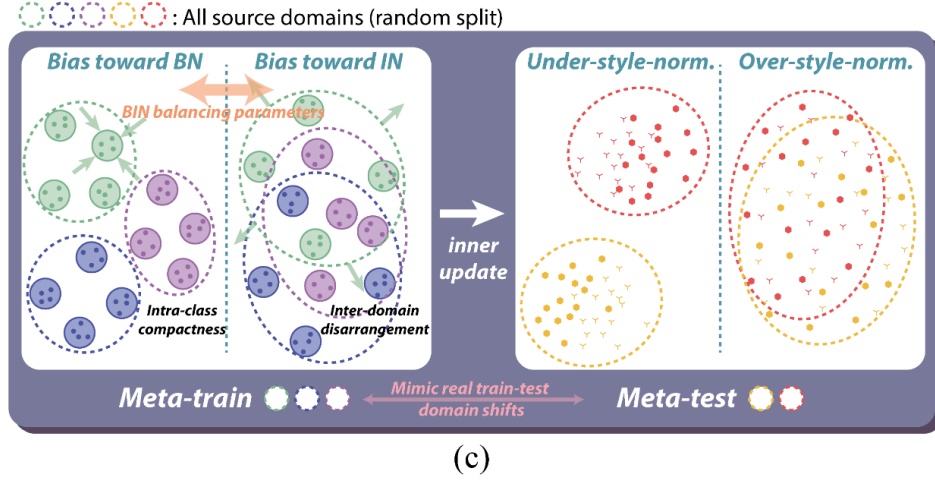


图 2: 论文中提出的框架

根本上提升了 ReID 模型的跨域泛化能力。MetaBIN 的工作原理如下：

3.2.1 BN 和 IN 的自适应平衡

MetaBIN 在 BN 和 IN 的基础上设计了一种自适应平衡机制，将两者结合为一个可学习的归一化层。在 MetaBIN 框架中，每一层归一化的平衡系数是可学习的，并通过元学习自动调整，以应对不同样本的风格变化。通过这种机制，MetaBIN 可以动态调节 BN 和 IN 的贡献，避免了单纯依赖某一类型归一化所带来的局限性，既保持了风格不变性，又保留了必要的个体信息。MetaBIN 的归一化过程可以表示为：

$$y = \rho(\gamma_B \cdot \hat{x}_B + \beta_B) + (1 - \rho)(\gamma_I \cdot \hat{x}_I + \beta_I)$$

\hat{x}_B 和 \hat{x}_I 分别表示经过 BN 和 IN 归一化后的特征， γ 和 β 是仿射变换参数， ρ 是平衡系数，用于动态调整 BN 和 IN 的权重。

3.2.2 失败情境模拟与元学习优化

MetaBIN 通过在元学习（Meta-Learning）过程中模拟失败情境，进一步提升模型在未知域上的泛化能力。具体而言，MetaBIN 使用一种“模拟失败”的策略，在训练过程中有意将模型推向“过归一化”或“欠归一化”的情境，使模型学会在多样化的失败情境下进行调整。例如，通过偏向 IN 模拟“过度归一化”的情况，以增强模型对新域的风格变化的适应能力；或通过偏向 BN 模拟“欠归一化”的情境，以确保模型在不同域中保留个体辨识能力。这种元学习的设计使得模型在训练过程中不仅适应了多样化的域风格，而且避免了过拟合到特定的风格和域分布。在元学习的过程中，MetaBIN 采用以下优化策略来更新模型参数：

$$\theta' = \theta - \alpha \nabla_{\theta} L(\theta)$$

θ 表示模型参数, $L(\theta)$ 表示损失函数, α 表示学习率。通过这种方式, MetaBIN 能够在每个训练阶段对模型参数进行微调, 以适应不同的归一化失败情境。

3.2.3 循环内更新的增强效果

在元学习的具体实现上, MetaBIN 引入了循环内更新 (Cyclic Inner-Update) 机制。这一机制通过对元学习过程中更新的步长进行循环调整, 模拟出更多的虚拟失败情境, 从而提升了模型的鲁棒性。不同于一般的固定步长更新, 循环内更新能在不同步长下呈现不同的泛化情境, 使得模型能在更广泛的情况下学习到泛化策略, 有效避免了模型在特定失败情境中的局限性。循环内更新的数学表达式为:

$$\theta_{t+1} = \theta_t - \beta_t \nabla_{\theta_t} L(\theta_t)$$

β_t 表示在第 t 个训练阶段的循环调整步长, 它可以根据预定义的策略进行周期性变化。

3.2.4 综合损失设计

为了进一步提高跨域性能, MetaBIN 在元学习过程中使用了综合损失函数, 包括三重损失 (Triplet Loss)、散布损失 (Scatter Loss) 和混淆损失 (Shuffle Loss) 等。在训练过程中, 这些损失函数共同作用, 既增加了样本间的多样性, 又减少了跨域间的分布差异。例如, 三重损失用于增强不同身份个体的区分性, 而混淆损失则通过将不同域的样本混合, 以最大化域之间的不可区分性, 从而提升跨域适应性。综合损失函数可以表示为:

$$L_{total} = L_{triplet} + \lambda L_{scatter} + \mu L_{shuffle}$$

$L_{triplet}$ 表示三重损失, $L_{scatter}$ 表示散布损失, $L_{shuffle}$ 表示混淆损失, λ 和 μ 是用于平衡不同损失项权重的超参数。

通过上述机制, MetaBIN 框架能够有效地提升 ReID 模型在未知域上的泛化能力, 同时避免了过拟合到特定的风格和域分布, 为跨域 ReID 任务提供了一种有效的解决方案。

3.3 MetaBIN 框架的过拟合缓解效果

MetaBIN 框架通过上述创新设计, 有效缓解了 ReID 模型的过拟合问题, 主要体现在以下几个方面:

3.3.1 增强跨域泛化能力

MetaBIN 框架显著增强了模型在不同监控场景下的泛化能力, 通过在元学习过程中模拟各种可能的归一化失败情况, 使模型能够学习到在面对全新、未见过的目标域时仍能保持稳定表现的能力。与传统的 ReID 模型相比, MetaBIN 不需要依赖额外的数据

Method	Large-scale domain generalization Re-ID (multi-source DG)																	
	Average		Target: VIPeR (V) [12]				Target: PRID (P) [15]				Target: GRID (G) [25]				Target: i-LIDS (I) [44]			
	R-1	mAP	R-1	R-5	R-10	mAP	R-1	R-5	R-10	mAP	R-1	R-5	R-10	mAP	R-1	R-5	R-10	mAP
DIMN [36]	47.5	57.9	51.2	70.2	76.0	60.1	39.2	67.0	76.7	52.0	29.3	53.3	65.8	41.1	70.2	89.7	94.5	78.4
AugMining [39]	51.8	-	49.8	70.8	77.0	-	34.3	56.2	65.7	-	46.6	67.5	76.1	-	76.3	93.0	95.3	-
Switchable (BN+IN) [27]	57.0	65.6	51.6	72.9	80.8	61.4	59.6	78.6	90.1	69.4	39.3	58.8	68.1	48.1	77.3	91.2	94.8	83.5
DualNorm [17]	57.6	61.8	53.9	62.5	75.3	58.0	60.4	73.6	84.8	64.9	41.4	47.4	64.7	45.7	74.8	82.0	91.5	78.5
DDAN [3]	59.0	63.1	52.3	60.6	71.8	56.4	54.5	62.7	74.9	58.9	50.6	62.1	73.8	55.7	78.5	85.3	92.5	81.5
DDAN [3] w/ [17]	60.9	65.1	56.5	65.6	76.3	60.8	62.9	74.2	85.3	67.5	46.2	55.4	68.0	50.9	78.0	85.7	93.2	81.2
MetaBIN (Ours)	64.7	72.3	56.9	76.7	82.0	66.0	72.5	88.2	91.3	79.8	49.7	67.5	76.8	58.1	79.7	93.3	97.3	85.5
SNR [†] [18]	57.3	66.4	52.9	-	-	61.3	52.1	-	-	66.5	40.2	-	-	47.7	84.1	-	-	89.9
DualNorm [†] [17]	62.7	-	59.4	-	-	-	69.6	-	-	-	43.7	-	-	-	78.2	-	-	-
MetaBIN [†] (Ours)	66.0	73.6	59.9	78.4	82.8	68.6	74.2	89.7	92.2	81.0	48.4	70.3	77.2	57.9	81.3	95.0	97.0	87.0

图 3: 模型的评测结果

增强或复杂的网络结构设计，就能够有效地减少对源域数据的过拟合现象。这种能力的提升，使得 MetaBIN 在处理来自不同摄像头、不同光照条件和不同季节的图像时，都能够保持较高的识别精度，从而在实际的跨域应用中展现出卓越的性能。

3.3.2 降低风格依赖性

MetaBIN 框架通过精心设计的虚拟模拟训练过程，显著降低了模型对于特定风格特征的依赖性。在训练过程中，MetaBIN 不仅模拟了常见的风格变化，还特别关注了那些极端和罕见的风格变化情况。这种全面的模拟训练使得模型在面对风格多变的目标域时，能够更加灵活地调整其内部参数，以适应新的环境。与传统的归一化方法相比，MetaBIN 的这种自适应能力极大地提高了模型在新领域中的鲁棒性，使其在面对风格差异较大的图像时，仍然能够准确地识别出目标个体。

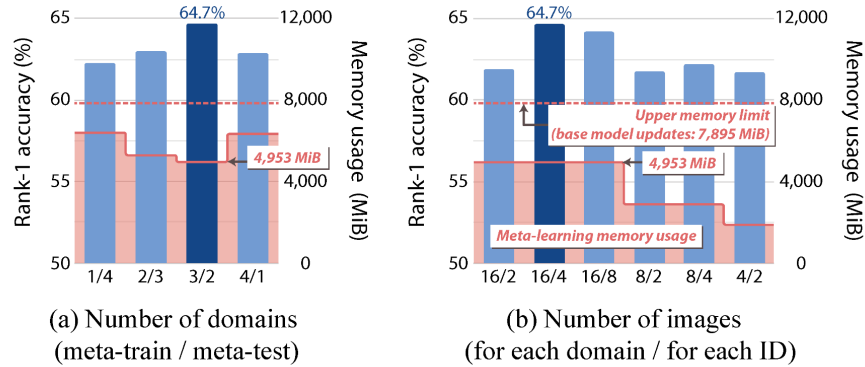


图 4: 域集采样的影响

3.3.3 维持身份辨识能力

在进行风格归一化的同时，MetaBIN 框架通过其创新的综合损失函数设计，确保了模型不会丢失对个体身份辨识能力。这一损失函数综合了交叉熵损失、三元组损失以及特有的域内散布损失和域间混淆损失，有效地平衡了模型在学习和泛化过程中的矛盾需求。与传统的 BN 和 IN 方法相比，MetaBIN 不仅能够去除无关的风格噪声，还能够

保留甚至增强那些对于个体辨识至关重要的信息。这种精细的平衡策略，使得 MetaBIN 在提高模型泛化能力的同时，还能够保持甚至提升模型在源域上的性能，解决了传统方法中常见的泛化与性能之间的权衡问题。

MetaBIN 框架不仅通过引入元学习和自适应归一化技术缓解了 ReID 模型中的过拟合问题，还为未来的跨域识别提供了一个高效的解决方案。其创新的失败情境模拟、循环内更新和综合损失设计使得模型在处理复杂跨域任务时，能够在多个失败情境中进行训练，从而显著提升了 ReID 模型的鲁棒性和泛化性能。

4 在深度学习领域的推广

在深度学习领域，模型的泛化能力是评价其性能的关键指标之一。而过拟合现象，即模型在训练集上表现优异但在未见数据上表现不佳的问题，是影响泛化能力的主要障碍。ReID 任务作为一种特定的深度学习应用，其过拟合问题的解决方案，尤其是本篇论文中的 MetaBIN 框架，为其他领域提供了宝贵的启示。

MetaBIN 框架的核心在于通过元学习策略，预先让模型在训练过程中经历各种可能的失败情境，以此提升模型在未知环境下的鲁棒性。这一策略不仅适用于 ReID 任务，同样可以推广至图像分类、语音识别和自然语言处理等其他深度学习任务。通过模拟不同的数据分布和噪声情况，模型能够在多样化的环境中学习到更加泛化的特征表示。

此外，MetaBIN 框架中的自适应归一化策略，即动态平衡批归一化（BN）和实例归一化（IN），为处理不同风格和分布的数据提供了新的视角。这种策略可以根据具体任务的需求，调整归一化方法以适应数据的特性，从而提高模型的泛化性能。循环内更新机制是 MetaBIN 框架的另一项创新，它通过周期性地改变更新步长，模拟出更多的虚拟失败情境。这种机制能够增强模型在面对多样化数据时的适应能力，对于提升模型在复杂环境中的稳定性和鲁棒性具有重要意义。MetaBIN 框架中综合损失函数的设计，通过结合三重损失、散布损失和混淆损失等，为模型提供了一种有效的训练信号。这种损失函数的设计理念可以定制化地应用于其他深度学习任务，以增强模型对不同数据风格的适应性和泛化能力。

综上，MetaBIN 框架的提出及其工作机制不仅在 ReID 任务中展现出显著的效果，而且其背后的原理和方法论具有更广泛的适用性。未来的研究可以进一步探索如何根据不同任务的特点，定制和优化 MetaBIN 框架中的策略和技术，以实现在更广泛的深度学习任务中的应用。通过这种方式，MetaBIN 框架有望为深度学习模型的泛化能力提升提供新的解决方案。

5 结论

本报告围绕目标重识别问题中的过拟合现象进行了深入探讨，并系统性地回顾了多种解决方案的发展过程。过拟合是机器学习，尤其是深度学习模型中的普遍问题，会导

致模型在训练集上表现良好，但在测试集或新数据上表现不佳。在 ReID 任务中，模型因依赖训练数据中的特定风格和环境信息，容易出现严重的过拟合问题，导致跨域识别性能低下。

MetaBIN 框架的提出，为解决过拟合提供了一个创新性的方法。MetaBIN 结合了批归一化 (BN) 和实例归一化 (IN) 的自适应平衡机制，并通过元学习模拟失败情境，使模型能够应对不同域间风格变化，增强了跨域泛化能力。该框架在 ReID 任务中表现优异，且无需复杂的数据增强或网络设计，不仅解决了模型在风格变化下的依赖问题，还提升了模型对目标个体的区分性。

MetaBIN 的创新方法在深度学习领域具有广泛的推广应用潜力。元学习策略及自适应归一化层设计，不仅适用于 ReID 任务，还可推广到图像分类、语音识别、自然语言处理等其他深度学习任务，帮助模型有效应对跨域挑战。MetaBIN 中提出的失败情境模拟与循环内更新机制，也为深度学习模型在复杂环境中的稳定性与鲁棒性提供了新思路，具备在多样化任务中提升模型泛化性能的潜力。

未来研究可以进一步探讨如何结合任务特点对 MetaBIN 进行优化，并在更多的深度学习任务中验证其性能。通过对不同任务和数据分布特性的适配，MetaBIN 框架有望成为解决过拟合、提升模型泛化能力的有效工具，为深度学习模型在实际应用中的性能提升提供支持。

参考文献

- [1] Choi, Seokeon, et al. "Meta batch-instance normalization for generalizable person re-identification." *Proceedings of the IEEE/CVF conference on Computer Vision and Pattern Recognition*. 2021.
- [2] Sharma, Vineet K., et al. "Fast and accurate taxonomic assignments of metagenomic sequences using MetaBin." *PLoS One* 7.4 (2012): e34030.
- [3] Jin, Xin, et al. "Style normalization and restitution for generalizable person re-identification." *Proceedings of the IEEE/CVF conference on Computer Vision and Pattern Recognition*. 2020.
- [4] Luo, Hao, et al. "A strong baseline and batch normalization neck for deep person re-identification." *IEEE Transactions on Multimedia* 22.10 (2019): 2597-2609.